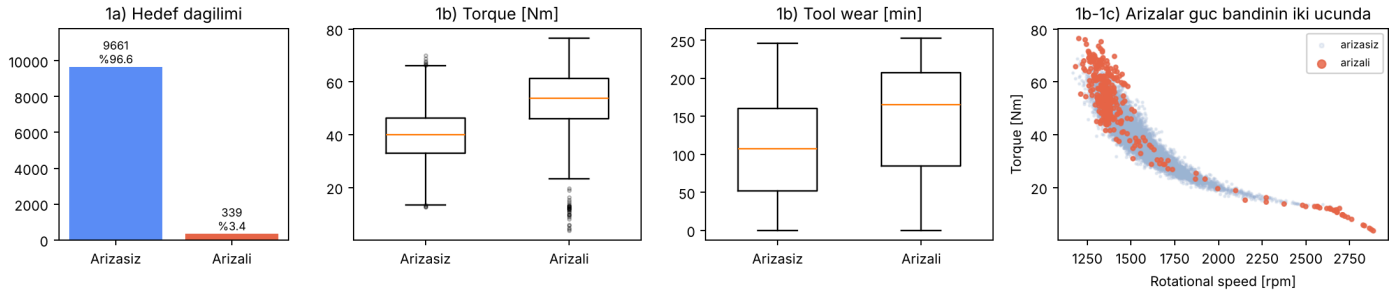
Soru 1 — Veriyi Tanıma ve Problemi Anlama

1a 10.000 kaydın 9.661'i arızasız (%96,6), 339'u arızalı (%3,4); sınıflar **1:28,5 dengesiz**. Bundan üç zorluk çıkıyor. (i) **Accuracy yanıltıcıdır:** hiçbir sensöre bakmadan herkese "sağlam" diyen kural %96,6 accuracy alır ama tek bir arızayı bile yakalamaz. Bu yüzden ana ölçüt olarak azınlık sınıfına odaklanan PR-AUC'yi, yanında recall, precision ve F1'i kullandım. (ii) **Azınlık sınıfı az:** 5 katlı CV'de kat başına ~54 arıza düşüyor, birkaç kayıt skoru oynatabiliyor. Bölme ve CV bu yüzden stratified. (iii) **Varsayılan 0,50 eşiği çoğunluk sınıfına kayar;** eşik ayrı bir karar olarak seçilmeli (3a). Ürün tipine göre arıza oranı L %3,92 · M %2,77 · H %2,09: düşük kaliteli ürün işleyen makineler yaklaşık iki kat daha sık arızalanıyor.

1b Beş sayısal değişkenin tamamında fark anlamlı (Mann-Whitney $p < 0{,}001$), ama etki büyüklükleri çok farklı:

Değişken	Arızasız ort. (medyan)	Arızalı ort. (medyan)	Std arızasız / arızalı	Cohen d
Torque [Nm]	39,6 (39,9)	50,2 (53,7)	9,5 / 16,4	**1,08**
Tool wear [min]	106,7 (107)	143,8 (165)	62,9 / 72,8	**0,59**
Air temperature [K]	299,97 (300,0)	300,89 (301,6)	2,0 / 2,1	0,46
Rotational speed [rpm]	1.540 (1.507)	1.496 (1.365)	**167 / 385**	−0,24
Process temperature [K]	310,00 (310,0)	310,29 (310,4)	1,49 / 1,36	0,20
Çalışma bandına göre arıza oranı (%)				
Tool wear [min]	≤100: 2,25	100–200: 2,54	**>200: 15,49**	
Torque [Nm]	≤30: 2,68	30–50: 1,24	50–60: 8,58	**>60: 41,95**
Rotational speed [rpm]	**≤1.380: 15,99**	1.380–1.600: 1,18	1.600–2.000: 0,64	**>2.000: 14,60**



Arızalı makinelerde tork ortalama 10,5 Nm, takım aşınması 37 dakika daha yüksek; bunlar en büyük iki etki. Devirde ortalama fark yalnızca −44 rpm, ama arızalı grubun standart sapması iki katından fazla. Yani arızayı "yüksek" ya da "düşük" devir değil, **normal çalışma bandının dışına çıkmak** getiriyor: devir 1.380–2.000 rpm arasındayken arıza oranı %0,6–1,2, iki uçta ise %15–16. Saçılım grafiği de aynı şeyi gösteriyor; arızalar tork–devir eğrisinin iki ucunda toplanıyor. Üretim yönetimi için çıkarım: **tork 60 Nm'yi aştığında her 10 kayıttan 4'ü arızalı, takım 200 dakikayı geçince arıza oranı 6 katına çıkıyor.** Takım değişimi 200 dakika civarına planlanmalı, 60 Nm üstü yükleme alarm sebebi sayılmalı.

1c Tek başına ayırt edicilik (ROC-AUC, 0,5 = şans): güç bandından sapma² 0,772 · tork 0,770 · devir 0,767 · tork×devir 0,746 · aşınma×tork 0,704 · sıcaklık farkı 0,662 · takım aşınması 0,662 · hava sıcaklığı 0,633 · süreç sıcaklığı 0,564. Bulgulara göre en yararlı olanlar:

- **Tork ve devir, birlikte.** Çarpımları mekanik güçtür ve arıza gücün iki ucunda görülür (U şekli). Bu yüzden "gücün normal banttan ne kadar saptığı" tek başına en güçlü gösterge; panelde tork ve devir ayrı ayrı değil, birlikte izlenmeli.
- **Takım aşınması, tork ile birlikte.** Tek başına orta güçte (0,662), ama yıpranmış takımın yüksek torkla zorlanmasını gösteren aşınma×tork belirgin biçimde daha güçlü (0,704).
- **Sıcaklıklar ayrı ayrı zayıf, farkları yararlı.** Süreç sıcaklığı en az bilgi taşıyan değişken; işe yarayan şey süreç − hava farkı. Fark küçükse makine ısıyı ortama atamıyor demektir.

Bu çıkarımlar modelde de doğrulandı: bu bilgilerden türetilen özellikler karar ağacının toplam Gini öneminin %65'ini taşıyor (2d). Not: Veri seti sentetiktir (UCI); sonuçlar tek makine tipine aittir.

Soru 2 — Arıza Tahmin Modellerinin Geliştirilmesi

2a Veri bölme, validasyon ve ön işleme:

- **Bölme:** %80 geliştirme (8.000 kayıt, 271 arıza) / %20 test (2.000 kayıt, 68 arıza), `stratify=y`, seed 42. Stratify şart, çünkü 339 arızanın rastgele bölünmesi testteki arıza sayısını oynatır. Veride tarih yok ve her UDI tek satır, bu yüzden zamansal veya grup bölmesine gerek kalmadı.
- **Validasyon:** Test kümesi hiçbir seçimde kullanılmadı, yalnızca sonuç raporlamak için ölçüldü. Bütün seçimler (temizlik, özellik, hiperparametre, eşik) geliştirme kümesinde 5 katlı stratified CV ile yapıldı. Satır atan temizlik yalnızca eğitim katlarına uygulandı; doğrulama katları ve test eksiksiz kaldı. Hiperparametre seçiminin skoru şişirip şişirmediği iç içe (nested) CV ile kontrol edildi.
- **Girdiler:** Type, hava ve süreç sıcaklığı, devir, tork, takım aşınması. TWF/HDF/PWF/OSF/RNF (arıza sonucu göstergeleri), UDI ve Product ID çıkarıldı.
- **Ön işleme:** Eksik değer ve mükerrer kayıt yok. Type sıralı kodlandı (L<M<H). LR ve KNN'de `StandardScaler` Pipeline içinde kullanıldı, çünkü birimler farklı (K, rpm, Nm) ve KNN mesafe tabanlı; ağaç ölçeklemeye duyarsız. Aykırı değerler silinmedi: uç değerler arızanın kendisi, silmek CV PR-AUC'yi düşürdü (−0,008). Arıza türü belirtilmemiş 7 "arızalı" kayıt eğitimden atıldı (CV +0,0095, 15 katın 12'sinde iyileşme). Devire log1p ve RNF temizliği CV'de kazandırmadığı için uygulanmadı.
- **Özellikler** (CV ile ileri seçim; kabul için ortalama kazanç ≥ 0,0005 ve 15 katın en az 9'unda iyileşme): güç bandından sapma² (eğitim medyanına göre, Pipeline içinde), aşınma×tork, güç [W] ve sıcaklık farkı kabul edildi; ısı yükü ve aşınma oranı elendi. Veri dokümanındaki kesin arıza eşiklerini bayrak olarak eklemek LR'yi 0,93'e çıkarıyordu, ama bu eşikler etiketi üreten kuralın kendisi olduğu için sızıntı sayıp eledim.

2b Test performansı (eşik 0,50). CV, geliştirme kümesinde 5 katlı PR-AUC; nested CV, ayar seçiminden arındırılmış tahmindir.

Model	Ayar (CV ile)	Accuracy	Precision	Recall	F1	PR-AUC	CV PR-AUC	Nested CV
Dummy (taban)	—	0,9660	0,0000	0,0000	0,0000	0,0340	0,034	—
Logistic Regression	C = 1	0,9695	0,6400	0,2353	0,3441	0,5007	0,530 ± 0,059	0,526
KNN	k = 25	0,9715	1,0000	0,1618	0,2785	0,6067	0,683 ± 0,046	0,686
Decision Tree	**depth 7, leaf 10**	**0,9895**	**0,9608**	**0,7206**	**0,8235**	**0,8482**	**0,883 ± 0,033**	**0,891**

Veri işlemenin katkısı (karar ağacı, CV PR-AUC): ham 0,470 → temizlenmiş 0,482 → özellikli 0,725 → ayarlı 0,883. Asıl kazanç öznitelik ve budamadan geldi; veri zaten temiz olduğu için temizliğin payı küçük kaldı. Nested CV düz CV'ye çok yakın, yani ayar seçimi skoru şişirmedi. Ağaç ile KNN arasındaki test PR-AUC farkının bootstrap %95 aralığı [0,145; 0,342]; sıfırı içermediği için fark gürültü değil. LR'nin zayıf kalmasının sebebi, arızanın doğrusal olmayan (U şeklinde) bir ilişkiyle gelmesi.

2c **Hayır.** Accuracy değerleri 0,966–0,990 arasında sıkışmış durumda; Dummy bile 0,966 alıyor. LR'nin 0,9695'i Dummy'den yalnızca 0,0035 fazla, ama 68 arızanın 52'sini kaçırıyor. Metrik değişince sıralama da değişiyor: KNN accuracy'de ikinci, recall'da sonuncu (DT 0,72 > LR 0,24 > KNN 0,16). Burada en yüksek accuracy'yi veren model (karar ağacı) aynı zamanda en iyi model, ama bunun gerekçesi accuracy değil; PR-AUC ve maliyet eşiğindeki recall/precision. Accuracy eşiğe de bağlı: aynı ağacın eşiğini 0,10'a indirince accuracy 0,990'dan 0,986'ya düşüyor, ama kaçırılan arıza 19'dan 11'e iniyor. Yani fabrika için daha iyi olan model, daha düşük accuracy'li olan.

2d **Seçim: karar ağacı** (`max_depth=7, min_samples_leaf=10`, 18 yaprak). Gerekçeler:

- **Performans ve kararlılık:** En yüksek PR-AUC ve en düşük CV sapması (±0,033) bu modelde.
- **Açıklanabilirlik:** Model durdurma önerdiğinde vardiya amiri "neden?" diye soracak; ağaç bunun cevabını bakım ekibinin okuyabileceği kurallarla veriyor. İlk kurallar:

```
Güç, normal banttan ~2,6 std'den fazla saparsa (çok düşük ya da çok yüksek güç) → ARIZA
Aşınma×Tork > 10.998 dk·Nm ve ürün tipi L → ARIZA (aşırı zorlanma)
Sıcaklık farkı ≤ 8,6 K ve devir ≤ 1.380 rpm → ARIZA (ısı atamama)
```

- **Operasyon:** Tahmin anında üretiliyor; ölçeklemeye bağlı olmadığı için sensör birimi değiştiğinde ölçekleyiciyi yeniden eğitmek gerekmiyor; KNN gibi bütün eğitim verisini bellekte tutmuyor. KNN'in precision'ı 1,00 ama 68 arızanın yalnızca 11'ini buluyor. LR yorumlanabilir ama recall'ı kullanılamayacak kadar düşük.
- **Kabul edilen zayıflık:** Tek ağaç, veri değiştiğinde kolay değişir. Bu yüzden periyodik yeniden eğitim ve kuralların mühendis onayından geçmesi gerekir.

Soru 3 — Modeli Gerçek Hayatta Kullanmak

3a **Kaçırılan arıza (yanlış negatif) daha kritik.** Bu hata plansız duruş demek: hat durur, işlenen parça hurdaya çıkar, kırılan takım çevredeki ekipmana zarar verebilir, teslimat gecikir; üstelik arızanın zamanını biz değil arıza seçer. Yanlış alarm ise planlı bakım maliyetidir: zamanı biz seçeriz ve makine çalışmaya devam eder. Yine de yanlış alarm sınırsız olamaz. Alarm sayısı bakım ekibinin kapasitesini aşarsa teknisyenler alarmlara güvenmeyi bırakır. Bu yüzden karar "1 kaçırılan arıza kaç yanlış alarma bedel?" sorusuyla verilmeli. Gerçek maliyet verisi olmadığı için 1:10 oranını varsayım olarak aldım; eşik yalnızca OOF (out-of-fold) tahminlerinden, bu maliyeti en aza indiren değer olarak seçildi: **0,105**.

1 kaçırılan arıza = k yanlış alarm	Eşik (OOF'tan)	Test TP	FP	FN	Recall	Precision
k = 1	0,667	49	0	19	0,721	1,000
k = 5	0,438	53	5	15	0,779	0,914
k = 10 (önerilen)	**0,105**	**57**	**17**	**11**	**0,838**	**0,770**
k = 20	0,015	61	97	7	0,897	0,386

Önerilen eşikte 68 arızanın 57'si yakalanıyor; 2.000 kayıtta 17 yanlış alarm çıkıyor. %95 güven aralıkları: recall [0,746; 0,921], precision [0,672; 0,868]. Testte yalnızca 68 arıza olduğu için birkaç puanlık farklar gürültü sınırında kalıyor. Aynı eşik OOF katlarında 0,78–0,91 arası recall veriyor, yani kararlı. Gerçek TL maliyetleri belli olduğunda tablodan uygun satır seçilir; bu karar modelin değil işletmenindir.

3b Arızaları yakalama başarısını artırmak için yapacağım değişiklikler ve olası olumsuz sonuçları (test sonuçları):

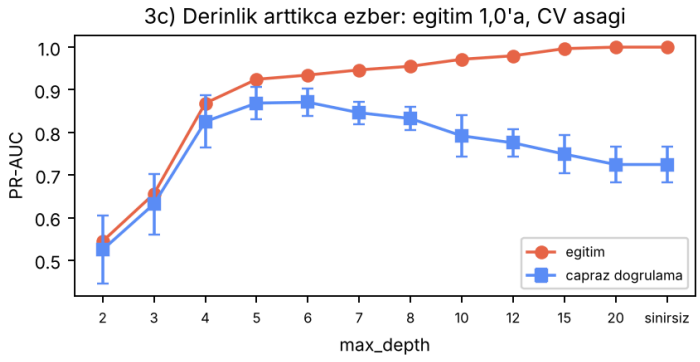
Değişiklik	Etkisi	Olası olumsuz sonucu
Eşiği 0,50 → 0,105 indirmek	Recall 0,72 → 0,84; kaçırılan 19 → 11	Yanlış alarm 2 → 17; precision 0,96 → 0,77
Eşiği daha da indirmek (k = 20, eşik 0,015)	Recall 0,90; kaçırılan 7	97 yanlış alarm: her 10 alarmdan 6'sı boşa, alarm yorgunluğu
`class_weight="balanced"`	Recall 0,90; kaçırılan 7	96 yanlış alarm; CV PR-AUC 0,883 → 0,835, sıralama gücü de bozuluyor. Eşik ayarı daha kontrollü
Takım aşınması (TWF) için ayrı kural	Kaçırılan 11 arızanın 8'i TWF, 2'si türü belirsiz kayıt. Model TWF'nin 10 vakasından 2'sini yakalıyor (HDF 28/29, PWF 13/13, OSF 16/16)	TWF 200–240 dk'da rastgele tetikleniyor. "200 dk'da takım değiştir" kuralı takım maliyetini artırır
Daha fazla arıza verisi toplamak	271 eğitim arızası seyrek; azınlık sınıfı daha iyi temsil edilir	Zaman alır; süreç değişirse eski veri geçerliliğini yitirir

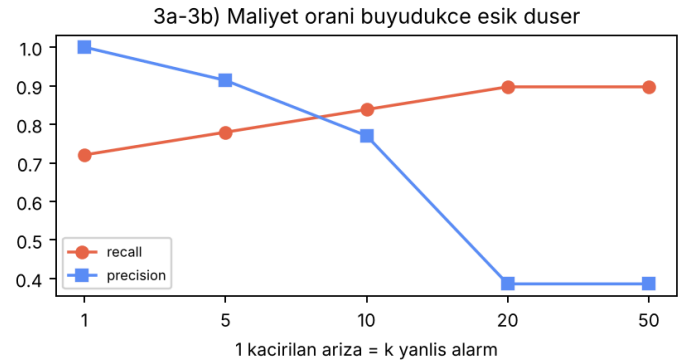
3c Bu durum **aşırı öğrenme** (ezberleme, yüksek varyans) olur. Teşhisi koymadan önce sızıntıyı ve hatalı bölmeyi dışladım: sızıntı denetiminin 7 maddesi geçti, eğitim ve testte arıza oranı aynı (0,034). Bu veri setinde aşırı öğrenme bizzat görüldü: budanmamış karar ağacı eğitimde PR-AUC 1,000, testte 0,611 aldı; 61 yaprak üretti ve bazı yapraklarda tek kayıt vardı. Grafikte derinlik 6'dan sonra eğitim skoru 1,0'a giderken CV skoru düşüyor.

Model	Eğitim	Test	Fark
DT budanmamış	1,000	0,611	**0,389**
DT ayarlı (7 / 10)	0,951	0,848	0,103
KNN k = 5	0,813	0,537	0,276
KNN k = 25	0,763	0,607	0,156

Öneri 1 — Model karmaşıklığını sınırlamak: Ağaçta `max_depth` ve `min_samples_leaf`, KNN'de büyük k. Ağaçta eğitim–test farkı 0,389'dan 0,103'e indi, test PR-AUC 0,611'den 0,848'e çıktı.

Öneri 2 — Kararları çapraz doğrulamayla vermek, testi kilitli tutmak: Ayarı tek bir bölmeye göre değil 5 katlı CV ile seçmek ve iç içe CV ile kontrol etmek (DT: düz 0,883, nested 0,891, şişirme yok).





Tüm sayılar `ai4i_ariza_tahmini.py` çıktısıdır (`outputs/`); seed 42 ile birebir tekrar üretilebilir. Topluluk yöntemleri (Random Forest) de varyansı düşürürdü, ancak case üç modeli belirlediği için kapsam dışında bırakıldı.